

AI 프로젝트 결과 보고서

Steam 게임 리뷰 감성분석 및 LLM 요약

LSTM vs DistilBERT 비교 · RAG 기반 리뷰 Q&A · Streamlit 웹 데모

과제명	Steam 리뷰 감성분석 모델 개발 및 LLM 요약·질의응답 데모
담당자	고무서
작성일	2026년 7월 6일

— CONTENTS

목차

- 01** 프로젝트 개요 추진배경 · 목적 · 파이프라인
- 02** 데이터 분석 및 전처리 원본 · 샘플링 · 정제 · 판별 토큰
- 03** 모델 학습 및 비교 설계 · 학습 전략 · 결과 · DistilBERT 채택
- 04** LLM 요약 · RAG Q&A RAG 색인·질의응답 · LLM 생성
- 05** 결론 및 향후 계획 성과 요약 · 한계와 개선 방향

추진 배경 및 목적


- ▶ 게임 구매 결정에 리뷰가 큰 영향을 주지만, 인기 게임은 **리뷰가 수만 건**이라 전체 여론을 파악하기 어렵다.
- ▶ 직접 학습한 **딥러닝 감성분류 모델**로 리뷰의 긍/부정을 판별하고, **LLM**으로 장단점을 자연어 요약하며, **RAG**로 리뷰 근거 기반 질의응답을 제공한다.
- ▶ 동일 데이터에서 **비사전학습(LSTM) vs 사전학습(DistilBERT)** 모델을 비교해 전이학습의 효과를 정량적으로 검증한다.

핵심 목표

게임 선택(또는 리뷰 직접 입력) → DistilBERT 긍/부정 분류 후:

- ▶ **장/단점 요약** — 긍정·부정 리뷰 그룹에서 각 3개씩 추출
- ▶ **총평 요약** — 긍/부정 비율을 반영한 여론 방향 2~3문장
- ▶ **질문 입력 (Q&A)** — 벡터 검색 top-5 리뷰를 근거로 LLM 답변

이를 **Streamlit 3탭 데모 앱**으로 구현·배포



데이터 원본 — Steam Reviews

641만

전체 리뷰 수

5개

컬럼 수

82:18

원본 라벨 비율 (추천:비추천)

영어

리뷰 언어

컬럼	의미	사용 여부
review_text	리뷰 본문 (영어)	모델 입력
review_score	추천 여부 — 1(추천) / -1(비추천)	감성 라벨 (1/0 변환)
app_name	게임 이름	게임별 분석·RAG 필터
app_id	Steam 게임 고유 번호	미사용
review_votes	리뷰 추천(도움됨) 수	미사용

출처 · Hugging Face Hub

[ksang/steamreviews](#) — Kaggle

"Steam Reviews" 데이터셋의 미리.
Steam 플랫폼의 실제 사용자 리뷰
6,417,106건.

라벨의 성격 · 별점이 아니라 사용자가 직접 선택한 **추천/비추천 이진 라벨**이라 감성 분류 지도학습에 그대로 쓸 수 있다.

샘플링·정제 등 모든 가공은 다음 슬라이드(전처리)에서 다룬다.

전처리 ① — 균형 샘플링




그림 1 · 균형 샘플 라벨 분포 · 리뷰 길이 분포
(01_download_data)

왜 균형 샘플링인가 · 원본은 추천 82% : 비추천 18%로 불균형이 심해, 그대로 학습하면 모델이 전부 긍정으로 찍는 **다수 클래스 붕괴**에 빠진다 (초기 실험에서 실제 발생).

방법 · 클래스별로 셔플 후 **각 5천 건씩 뽑아 50:50 균형 샘플 1만 건** 구성. 앞부분만 자르면 특정 게임에 편중되므로 반드시 셔플 후 샘플링.

길이 분포 · 짧은 리뷰에 치우친 역함수형 — 절반 이상이 50단어 미만, 1,000단어 + 극단 장문은 임 복사붙여넣기가 다수.

균형 test셋의 accuracy는 실제 서비스 분포 (82:18)에서의 성능과 다름을 해석 시 유의.

전처리 ② — 노이즈 진단




그림 2 · 노이즈 유형별 진단 — 정제 규칙의 근거 (01_download_data)

정제 규칙을 정하기 전에 무엇이 얼마나 오염돼 있는지 먼저 정량화했다. 이 진단이 다음 슬라이드 정제 규칙의 직접 근거다.

- ▶ "Early Access Review" 자동 삽입 문구 **약 16%** — 감성과 무관한 최대 노이즈
- ▶ HTML 엔티티(" 등) 약 2%, BBCode·URL·3회+ 반복문자 다수
- ▶ 영숫자 없는 기호-only 리뷰, 3단어 미만 초단문 — 감성 신호 없음
- ▶ 결측치는 review_text 0.1% 수준으로 미미

전처리 ③ — 정제 파이프라인 전/후 비교

텍스트 정규화

HTML 엔티티 복원, Early Access 보일러플레이트·BBCode·URL 제거, 3회+ 반복문자 축약 (sooooo→soo), 구두점 분리

행 필터링

결측·빈 문자열·중복 제거, 영숫자 없는 기호-only 리뷰 제거, 3단어 미만 초단문 제거 — 무신호 리뷰 차단

라벨 변환 · 분할

review_score 1/-1 → 1(긍정)/0(부정), 라벨 비율을 유지하는 계층 분할 70/15/15 (seed 고정 재현성)




그림 3 · 전/후 리뷰 수·어휘 크기·평균 길이 (02_preprocessing)




그림 4 · 리뷰 길이 분포 전/후 오버레이 (02_preprocessing)

전처리로 어휘 크기 약 27% 감소(27,014 → 19,864) — LSTM 공백 토큰라이저의 어휘 낭비를 줄여 학습 효율 개선. 계층 분할 결과 각 스플릿의 긍정 비율이 50.7%로 일치(그림 5 생략).

전처리 ④ — 감성별 판별 토큰




그림 5 · 긍정/부정 판별 토큰 |log-odds| 상위 20 — 문서 빈도 집계 (02_preprocessing)

가장 영향력 큰 판별 토큰 · 긍정에서는 **surprisingly**가 1위 — 긍정 리뷰 26건에 등장하는 동안 부정에는 단 1건("기대 이상"의 반전 표현). 이어 **awesome**(오타 포함), 10/10·11/10·9/10 점수 표기, **addicting**, **childhood**가 상위권이다.

부정 1위는 **uninteresting**(부정 20건, 긍정 0건). **unacceptable**, **pathetic**, **worthless**, **scam**, **uninstalled** 등 환불·삭제로 이어지는 강한 어휘와, "기대만 컸다"는 **hyped**가 뒤따른다 — 부정 리뷰가 긍정보다 훨씬 단정적인 어휘를 쓴다는 것을 보여준다.

분석 과정에서 잡은 통계 왜곡

- ▶ 밌 리뷰 1건이 "salad"를 48회 반복 → 부정 판별 토큰 오염 → 문서 빈도(리뷰당 1회)로 집계 전환
- ▶ (ㄹㅇ) 밌 조각·그린텍스트 기호 (>) → 영숫자 없는 토큰 제외 필터
- ▶ 특정 게임 캐릭터명(고유명사) 혼입 → 샘플링 편향으로 명시, 해석 시 유의

모델 설계 — LSTM 베이스라인 vs DistilBERT

LSTM (비사전학습 베이스라인)

공백 토큰라이저



Embedding 100d



LSTM 128



Linear 2

어휘·임베딩을 처음부터 학습. min_freq=2 어휘 구축, PAD=0/UNK=1. 사전지식 없이 이 데이터만으로 학습하는 **대조군**.

DistilBERT (사전학습 파인튜닝)

WordPiece 토큰라이저



distilbert-base-uncased



분류 헤드 2

대규모 코퍼스 사전학습 지식 위에 파인튜닝. HF Trainer + DataCollatorWithPadding, max_len 128.

학습 전략 — 수렴 제어 및 최적 모델 선택

LSTM

파라미터 · Adam(lr 1e-4) · batch 128 · 임베딩 100차원 · hidden 128 · 최대 512토큰

결과 · train loss 0.362 / val loss 0.501 → **test accuracy 0.763 · F1 0.753**





그림 6 · LSTM train/val loss (03_train_lstm)

DistilBERT — 파인튜닝

파라미터 · AdamW(lr 5e-5) · 유효 배치 16(8×누적 2) · 최대 128토큰 · 사전학습 가중치 미세 조정

결과 · 평균 train loss 0.481 / val loss 0.591 → **test accuracy 0.856 · F1 0.855**



공통 통제: 동일 데이터(균형 1만)·동일 분할(70/15/15)·seed 42 고정·동일 지표(Accuracy/F1).

학습 결과 및 모델 비교

모델	ACCURACY	F1
LSTM (비사전학습)	0.763	0.753
DistilBERT (사전학습)	0.856	0.855

- ▶ **LSTM** · 부정 recall 81.1% vs 긍정 recall 71.6% — 긍정 175건을 부정으로 오판하는 **비대칭 판별**. 총 오류 289건.
- ▶ **DistilBERT** · 부정 85.9% / 긍정 85.1%로 **양 클래스 균형 판별**. 총 오류 177건 — LSTM 대비 39% 적음.

동일 조건: 균형 1만 건 · 동일 분할 · 균형 test(기저율 50%). 격차 +9.3%p = 전이학습의 효과.




그림 8 · LSTM 혼동 행렬 (03_train_lstm)




그림 9 · DistilBERT 혼동 행렬 (04_train_distil)

지표 비교 요약





그림 10 · LSTM vs DistilBERT Accuracy·F1 비교 (05_compare_models)



학습 곡선이 말하는 것

train 1k→5.7k에서 **LSTM은 +11.8%p**(0.638→0.756) 오르지만 아직 상승 중 — 임베딩부터 새로 배우느라 데이터에 굶주린 상태다. 반면 DistilBERT 참고선(0.856)은 모든 지점 위에 있다. **사전학습 =** 수만 건 분량의 데이터를 공짜로 얻는 효과.

최종 모델 선정 — DistilBERT

accuracy·F1 우위(+9.3%p)에 더해 양 클래스를 **균형 있게 판별**하고 데이터 증가 없이도 안정적인 성능을 내는 점을 근거로 **DistilBERT를 최종 모델로 채택**했다. 웹 데모의 게임 분석·리뷰 분류가 모두 이 모델(HF Hub 배포본)로 동작한다.

RAG ① — 리뷰를 벡터로 저장해 둔다 (색인)

LLM에게 그냥 물으면 학습 데이터에 없는 게임 정보를 **지어낼(환각)** 수 있다. RAG는 **실제 리뷰를 근거로 쥐여주는** 구조인데, 그러려면 먼저 리뷰를 **검색 가능한 형태로 저장해** 둬야 한다.

리뷰 10,810건

→

① 임베딩 (all-MiniLM-L6-v2)

→

② Chroma에 저장

① 임베딩 — 문장을 숫자 벡터로

임베딩 모델이 리뷰 한 건을 **384개의 숫자(벡터)**로 바꾼다. 핵심 성질: **의미가 비슷한 문장일수록 가까운 벡터**가 된다 — "so fun"과 "really enjoyable"은 단어가 달라도 벡터로는 이웃이 된다. 이 성질 덕분에 나중에 "의미로 검색"이 가능해진다.

② Chroma 저장 — 벡터 + 원문 + 꼬리표

벡터만 저장하면 검색 후 보여줄 것이 없으므로, Chroma에는 **벡터·리뷰 원문·메타데이터(게임 이름, 긍정/부정 라벨)**를 한 세트로 저장한다. 게임 이름 꼬리표 덕분에 "이 게임 리뷰 중에서만 검색"이 가능하다. 결과물은 89MB 파일로 영속화되어 배포 환경에서 그대로 쓴다.

이 색인 작업은 **한 번만** 수행한다. 질문할 때마다 1만 건을 다시 임베딩하면 매번 수십 초가 걸리므로, 미리 계산해 저장해 두는 것.

RAG ② — 질문이 오면 이렇게 답한다 (질의응답)

사용자가 게임을 고르고 질문하면, 저장해 둔 색인에서 근거를 찾아 LLM에게 건네는 과정이 실시간으로 일어난다.



① 질문 임베딩

색인 때와 같은 임베딩 모델로 질문을 벡터로 바꾼다. 같은 공간에 있어야 거리 비교가 성립한다.

② 의미로 검색

선택한 게임의 리뷰 중에서 질문과 의미가 가장 비슷한 리뷰 5개를 고른다(코사인 유사도). 키워드가 달라도 잡힌다 — "buggy?"로 물어도 "crashes constantly"가 검색됨.

③ 근거 기반 생성

찾은 리뷰 5개를 LLM에게 건네며 "이 리뷰들에 있는 내용으로만 답하고, 없으면 모른다고 답하라"고 지시. 답변 옆에 근거 원문도 노출해 검증 가능.

실행 예 — The Witcher 3 선택 후 "is this game worth buying?" → "돈이 아깝지 않다", "10/10" 등 근거 5건을 인용한 한국어 답변. LLM의 역할은 다음 슬라이드에서.

LLM — 받은 근거를 문장으로 바꿔주는 역할

LLM(**Qwen2.5-7B-Instruct**)은 스스로 게임을 평가하지 않는다. 앞 단계가 골라준 리뷰들을 읽고, 그 내용을 한국어 문장으로 정리해 주는 역할만 한다. 쓰이는 곳은 두 군데다.

분류기가 나눈 긍정/부정 리뷰 + 비율

→

Qwen2.5

→

총평 + 장점 3 + 단점 3

검색으로 찾은 근거 리뷰 5개 (앞 슬라이드)

→

Qwen2.5

→

질문에 대한 답변

쓰임새 ① 총평·장단점 요약

DistilBERT가 리뷰를 긍정/부정으로 나눠 주면, LLM에게 "**긍정 60% / 부정 40%**"라는 비율과 함께 **두 묶음을 건네며** 요약을 부탁한다. 긍정 묶음에서 장점 3개, 부정 묶음에서 단점 3개를 뽑고, 비율을 반영한 총평을 쓴다. **분류기가 재료를 나누고, LLM이 글로 정리하는 분업**이다.

쓰임새 ② Q&A 답변

앞 슬라이드에서 검색된 근거 리뷰를 받아 답변을 쓴다 (지시·환각 방지는 RAG ③ 참조). 여기서 주목할 점은 **같은 LLM이 입력만 달리해 두 기능을 수행**한다는 것 — 분류 결과를 받으면 요약이, 검색 결과를 받으면 답변이 된다.

1차 모델이 응답에 실패하면 예비 모델(Llama-3.3-70B)이 자동으로 대신 답한다. 모든 계산은 Hugging Face 서버에서 이루어져 서비스 컴퓨터의 자원을 쓰지 않는다.

결론 및 향후 계획

성과 요약

- ▶ 노이즈 진단 → 근거 기반 전처리 파이프라인 구축 (보일러플레이트 16% 제거 등)
- ▶ 불균형 데이터의 다수 클래스 붕괴를 진단하고 균형 샘플링으로 해결
- ▶ LSTM vs DistilBERT 비교: accuracy **+9.3%p** — 전이학습 효과 정량 검증, **DistilBERT 최종 채택**
- ▶ 분류·총평/장단점 요약·RAG Q&A를 결합한 **Streamlit 3탭 데모 배포 완료** (모델은 HF Hub 공개)

한계점 → 개선 방향

한계점

성능 수치는 긍/부정 50:50 시험지 기준 — 긍정이 82%인 **실제 환경에서의 점수와는 다름**

특정 게임 리뷰가 한쪽 감성에 쏠린 우연 때문에 **캐릭터 이름이 감성 단어처럼 집계됨**

영어 리뷰 한정

반어법·혼합 감성 오분류

개선 방향

실제 비율 (82:18) 그대로의 test셋을 추가로 만들어 두 점수를 함께 보고

샘플을 키우거나, 게임별로 긍/부정을 고르게 뽑아(층화 샘플링) 쏠림 제거

다국어 모델 (mBERT 등)로 확장

오분류 사례 분석 기반 데이터 보강